

Machine Learning

Tabla de contenidos

1	Cuando las reglas dejan de escribirse	3
1.1	El momento adecuado	4
1.2	¿Que es aprender?	5
1.3	¿De dónde y cómo aprender?	6
1.3.1	Aprendizaje supervisado	6
1.3.2	Aprendizaje no supervisado	7
1.3.3	Aprendizaje por refuerzo	7
1.3.4	Aprendizaje autosupervisado	8
1.4	Los algoritmos de aprendizaje	8

1 Cuando las reglas dejan de escribirse

La Inteligencia Artificial simbólica demostró que un ordenador podía razonar utilizando conocimiento representado mediante reglas. Fue un enorme avance respecto a todo lo que habíamos visto hasta ese momento, ya que por primera vez una máquina no solo ejecutaba instrucciones, sino que era capaz de utilizar conocimiento explícito para tomar decisiones y obtener nuevas conclusiones mediante procesos de inferencia. Sin embargo, aquel éxito también puso de manifiesto una limitación fundamental que acabaría condicionando toda la evolución posterior de la Inteligencia Artificial: alguien tenía que escribir ese conocimiento.

Cada nueva situación requería nuevas reglas, cada excepción obligaba a modificar la base de conocimiento, cada cambio en el dominio implicaba revisar cientos o miles de reglas para mantener la coherencia del sistema. En consecuencia, la calidad de la aplicación dependía directamente de la capacidad de los expertos para expresar de forma explícita todo aquello que sabían. Mientras el conocimiento permanecía relativamente estable, este enfoque producía resultados excelentes, pero conforme los problemas crecían en complejidad, también lo hacía el número de reglas necesarias para describirlos.

Durante años se intentó resolver esta dificultad ampliando las bases de conocimiento y construyendo motores de inferencia cada vez más sofisticados, parecía razonable pensar que bastaría con añadir más reglas para obtener sistemas más inteligentes. Sin embargo, la realidad demostró que muchos de los problemas más interesantes no podían describirse de esa manera. No porque las herramientas fueran insuficientes, sino porque ni siquiera los propios expertos eran capaces de explicar con precisión cómo alcanzaban determinadas conclusiones.

Pensemos, por ejemplo, en una tarea aparentemente sencilla como reconocer un gato en una fotografía. Cualquier persona puede hacerlo en una fracción de segundo, incluso aunque el animal aparezca parcialmente oculto, esté tumbado, salte, sea completamente negro o la imagen tenga poca calidad, sin embargo, transformar esa capacidad en un conjunto de reglas resulta extraordinariamente difícil. Podemos empezar diciendo que un gato tiene cuatro patas, dos orejas, bigotes y cola, pero inmediatamente aparecerán decenas de excepciones: Existen gatos sin cola, fotografías donde apenas se distinguen las patas, animales vistos desde ángulos poco habituales o imágenes donde gran parte del cuerpo permanece oculta. Cada nueva regla parece generar nuevas excepciones y el sistema crece en complejidad sin acercarse realmente a la capacidad de reconocimiento de una persona.

El mismo problema aparecía en muchos otros ámbitos. Reconocer la voz de una persona, traducir automáticamente un texto, detectar un fraude bancario, interpretar una radiografía o comprender el significado de una frase eran tareas para las que resultaba mucho más sencillo mostrar ejemplos que escribir las reglas necesarias para resolverlas, poco a poco comenzó a surgir una idea que rompía con todo lo aprendido hasta entonces.

¿Y si las reglas no tuvieran que escribirse?

1.1. El momento adecuado

En ocasiones tendemos a pensar que las grandes revoluciones tecnológicas aparecen de forma repentina, como consecuencia de una idea brillante que cambia el mundo de un día para otro. Sin embargo, la historia de la ciencia y de la ingeniería demuestra que esto ocurre muy pocas veces. La mayoría de las ideas importantes aparecen mucho antes de que la tecnología sea capaz de aprovecharlas plenamente. Permanecen durante años, e incluso décadas, como propuestas prometedoras cuyo verdadero potencial todavía no puede demostrarse. Machine Learning constituye uno de los mejores ejemplos de este fenómeno.

Aunque hoy asociamos el aprendizaje automático con la Inteligencia Artificial moderna, sus fundamentos comenzaron a desarrollarse mucho antes. En 1959, Arthur Samuel, investigador de IBM y uno de los grandes pioneros de esta disciplina, utilizó por primera vez el término *Machine Learning* (Samuel 1959). para describir programas capaces de mejorar su comportamiento a partir de la experiencia, sin necesidad de que cada decisión estuviera programada explícitamente. Su conocido programa para jugar a las damas aprendía analizando partidas anteriores y modificando progresivamente su estrategia, la idea era extraordinariamente innovadora, pero también profundamente adelantada a su tiempo.

El verdadero problema no residía en los algoritmos, la idea de aprender a partir de la experiencia ya existía, lo que faltaba era la experiencia y, sobre todo, la capacidad necesaria para procesarla. Aprender implica observar una enorme cantidad de ejemplos, analizarlos repetidamente, detectar regularidades, corregir errores y volver a intentarlo una y otra vez hasta construir un modelo suficientemente fiable, todo ello requiere una capacidad de cálculo que durante buena parte del siglo XX simplemente no estaba disponible, incluso problemas relativamente modestos podían necesitar horas o días de procesamiento en ordenadores cuya potencia resulta hoy insignificante comparada con la de cualquier teléfono móvil.

Sin embargo, disponer de procesadores más rápidos tampoco habría sido suficiente, un ser humano aprende de su experiencia, y para una máquina esa experiencia está formada por datos. Durante décadas esos datos apenas existían en formato digital, las fotografías permanecían guardadas en álbumes familiares, las historias clínicas ocupaban archivadores, las conversaciones desaparecían una vez terminaban y la inmensa mayoría de la información generada por personas y organizaciones nunca llegaba a almacenarse de forma que pudiera ser utilizada por un algoritmo. Las máquinas podían aprender, pero apenas tenían nada de lo que aprender.

La situación comenzó a cambiar con la expansión de Internet y la progresiva digitalización de la sociedad. Cada fotografía realizada con un teléfono móvil, cada búsqueda en un navegador, cada compra por Internet, cada operación bancaria, cada mensaje publicado en una red social o cada sensor conectado a una red empezó a generar información de manera continua. Sin apenas darnos cuenta, la humanidad comenzó a construir el mayor repositorio de experiencia jamás disponible para una máquina, por primera vez existían millones de ejemplos reales

sobre prácticamente cualquier actividad humana, y esa inmensa cantidad de información podía utilizarse para entrenar modelos cada vez más precisos.

Solo cuando coincidieron estas circunstancias, algoritmos suficientemente maduros, ordenadores con la potencia necesaria para ejecutarlos y cantidades masivas de datos sobre los que aprender, *Machine Learning* pudo abandonar el ámbito de la investigación para convertirse en una tecnología capaz de resolver problemas reales. La revolución no fue consecuencia de un único descubrimiento, sino de la convergencia de varias revoluciones independientes que, finalmente, coincidieron en el momento adecuado.

1.2. ¿Que es aprender?

Para un ser humano, aprender significa adquirir conocimiento a partir de la experiencia, aprendemos a reconocer un rostro después de verlo varias veces, a conducir tras muchas horas de práctica o a distinguir una melodía simplemente porque la hemos escuchado antes. Nuestro cerebro trabaja con conceptos, recuerdos, sensaciones y significados. Un ordenador, sin embargo, no dispone de ninguno de esos elementos, no comprende qué es un gato, una carretera o una conversación, de hecho, ni siquiera sabe que existen, todo lo que recibe son números.

Esta idea resulta tan sencilla como trascendental. Una fotografía no es más que una enorme matriz de valores numéricos que representan la intensidad o el color de cada píxel, una grabación de voz es una secuencia de muestras digitales, un texto termina convirtiéndose en códigos, identificadores o vectores matemáticos. Antes de que una máquina pueda aprender cualquier cosa, la realidad debe transformarse en una representación numérica sobre la que sea posible realizar cálculos, ese proceso, invisible para la mayoría de los usuarios, constituye uno de los pilares de toda la Inteligencia Artificial moderna.

¿Qué significa entonces aprender para una máquina? Evidentemente no significa comprender el mundo como lo hace una persona, aprender consiste en descubrir relaciones matemáticas entre esos números. Si determinadas combinaciones aparecen repetidamente asociadas a un resultado correcto, el sistema ajusta progresivamente su comportamiento para que, cuando vuelva a encontrar patrones similares, produzca una respuesta parecida. No sabe que está identificando un gato, traduciendo un idioma o detectando un fraude bancario, lo único que hace es reconocer estructuras numéricas cuya aparición se ha relacionado previamente con un determinado resultado.

Esta diferencia puede parecer una simple cuestión técnica, pero representa un cambio profundo en la forma de entender el software. Durante décadas, el conocimiento residía en las reglas escritas por el programador. Con *Machine Learning*, el conocimiento deja de describirse explícitamente y pasa a emerger del análisis de los datos. El ingeniero ya no intenta capturar directamente el conocimiento del experto; construye un sistema capaz de descubrir, mediante procedimientos matemáticos, las relaciones ocultas que existen en la información disponible; esa es, probablemente, la mayor transformación que ha vivido la Ingeniería del Software desde sus orígenes.

1.3. ¿De dónde y cómo aprender?

Ningún ser vivo aprende de la nada y una máquina tampoco, todo aprendizaje requiere una fuente de experiencia sobre la que observar, comparar y extraer conclusiones. En los seres humanos esa experiencia procede de nuestros sentidos y de la interacción con el mundo, vemos, escuchamos, leemos, experimentamos y, poco a poco, construimos un conocimiento que nos permite comprender situaciones nuevas. Un ordenador, sin embargo, carece de ojos, oídos o intuición. Su única fuente de experiencia son los datos.

Esos datos pueden proceder de muy diversos lugares: Una cámara genera millones de píxeles que describen una imagen, un micrófono convierte el sonido en muestras digitales, los sensores de un automóvil registran velocidad, distancia o temperatura, una empresa almacena millones de transacciones realizadas por sus clientes, incluso un texto como el que el lector tiene ahora mismo delante acaba transformándose en una representación numérica. Aunque su origen sea muy diferente, para un ordenador todos ellos tienen algo en común: son conjuntos de números sobre los que es posible realizar operaciones matemáticas.

Sin embargo, disponer de datos no implica haber aprendido. Una biblioteca llena de libros no convierte a nadie en experto si nunca abre uno, del mismo modo, almacenar millones de fotografías o miles de millones de registros carece de utilidad si el sistema es incapaz de descubrir qué información contienen. Los datos constituyen la materia prima del aprendizaje, pero todavía es necesario un proceso que permita encontrar en ellos regularidades, relaciones y patrones que puedan utilizarse para responder a situaciones futuras.

Ese proceso es lo que denominamos **entrenamiento**. Durante el entrenamiento, el sistema analiza una enorme cantidad de ejemplos, realiza predicciones, compara sus resultados con la realidad cuando esta es conocida y ajusta internamente su comportamiento para reducir sus errores. Este ciclo se repite una y otra vez, miles o incluso millones de veces, refinando progresivamente el modelo hasta que es capaz de responder con una precisión suficiente a datos que nunca había visto.

Naturalmente, este proceso no ocurre de forma espontánea. Alguien debe diseñar el método que permita buscar esas relaciones matemáticas y decidir cómo modificar el modelo en cada iteración, ese método recibe el nombre de **algoritmo de aprendizaje**, y constituye el verdadero motor que hace posible el *Machine Learning*.

1.3.1. Aprendizaje supervisado

La forma más intuitiva de enseñar a una máquina consiste en mostrarle ejemplos junto con la respuesta correcta. Es el mismo método que utilizamos con frecuencia en el aprendizaje humano, un profesor plantea ejercicios y posteriormente corrige los errores del alumno, un padre enseña a un niño el nombre de los animales señalándolos uno a uno y un médico residente aprende contrastando sus diagnósticos con la opinión de un especialista. En todos estos casos existe una referencia que permite saber si la respuesta es correcta o incorrecta.

En Machine Learning este enfoque recibe el nombre de **aprendizaje supervisado**. Durante el entrenamiento, el modelo recibe una gran cantidad de ejemplos correctamente etiquetados

y utiliza esa información para ajustar progresivamente su comportamiento, si una imagen contiene un gato, el conjunto de datos indica que la respuesta correcta es “gato”; si un correo electrónico es fraudulento, esa información también forma parte de los datos de entrenamiento. Comparando continuamente sus predicciones con la respuesta esperada, el algoritmo reduce sus errores hasta construir un modelo capaz de realizar predicciones sobre casos que nunca había visto.

El aprendizaje supervisado se ha convertido en uno de los paradigmas más utilizados de la Inteligencia Artificial moderna porque resulta especialmente eficaz cuando existen grandes volúmenes de datos etiquetados. Clasificar imágenes, reconocer voz, detectar fraude bancario o predecir el precio de una vivienda son solo algunos ejemplos de problemas que pueden abordarse mediante este enfoque.

1.3.2. Aprendizaje no supervisado

No siempre es posible disponer de la respuesta correcta, en muchas ocasiones solo existen los datos y nadie sabe realmente qué estructuras esconden. Una empresa puede almacenar millones de operaciones de sus clientes sin conocer qué perfiles de comportamiento existen, un observatorio astronómico puede registrar enormes cantidades de información sin saber qué fenómenos contiene o un laboratorio puede acumular datos experimentales esperando descubrir relaciones desconocidas.

En estas situaciones se utiliza el **aprendizaje no supervisado**. El objetivo ya no consiste en imitar una respuesta conocida, sino en descubrir automáticamente patrones, agrupaciones o relaciones presentes en los propios datos. El algoritmo busca similitudes, identifica estructuras repetidas y organiza la información siguiendo criterios puramente matemáticos, no aprende porque alguien le diga cuál es la respuesta correcta, sino porque encuentra regularidades que permanecían ocultas entre millones de observaciones.

Este tipo de aprendizaje ha resultado especialmente útil para segmentar clientes, detectar anomalías, reducir la complejidad de grandes volúmenes de información o descubrir conocimiento previamente desconocido, en cierto modo, representa la faceta más exploratoria del *Machine Learning*, aquella en la que el objetivo no es confirmar lo que ya sabemos, sino encontrar aquello que todavía ignoramos.

1.3.3. Aprendizaje por refuerzo

Existe una tercera forma de aprender que se aproxima mucho más a la experiencia directa. En lugar de recibir respuestas correctas o limitarse a buscar patrones, el sistema interactúa con un entorno, toma decisiones y observa las consecuencias de sus acciones. Cada decisión puede producir un resultado favorable o desfavorable y esa información sirve para modificar su comportamiento futuro.

Este paradigma recibe el nombre de **aprendizaje por refuerzo**. El algoritmo aprende mediante un proceso continuo de prueba y error, intentando maximizar una recompensa acumulada a lo largo del tiempo. Igual que una persona mejora jugando al ajedrez después

de miles de partidas o un niño aprende a montar en bicicleta tras numerosas caídas y correcciones, el modelo perfecciona su estrategia a medida que experimenta con nuevas situaciones y evalúa los resultados obtenidos.

El aprendizaje por refuerzo ha demostrado una enorme capacidad para resolver problemas en los que es necesario tomar decisiones secuenciales. La planificación de rutas, la robótica, la conducción autónoma o los sistemas capaces de competir en videojuegos complejos son algunos de los campos donde este enfoque ha alcanzado resultados espectaculares, mostrando que una máquina también puede aprender a actuar cuando la experiencia es su único maestro.

1.3.4. Aprendizaje autosupervisado

Durante muchos años se pensó que entrenar un modelo requería enormes cantidades de datos etiquetados manualmente, sin embargo, etiquetar millones o miles de millones de ejemplos resulta costoso, lento y, en muchos casos, simplemente imposible. La evolución reciente de la Inteligencia Artificial ha demostrado que existe otra alternativa: utilizar los propios datos para generar automáticamente las tareas de aprendizaje.

En el **aprendizaje autosupervisado** no es necesario que una persona indique cuál es la respuesta correcta para cada ejemplo, es el propio algoritmo quien crea problemas cuya solución puede obtener a partir de la información disponible. Un modelo de lenguaje, por ejemplo, puede aprender intentando predecir la siguiente palabra de un texto o reconstruir una palabra que ha sido ocultada deliberadamente, una red neuronal que procesa imágenes puede aprender reconstruyendo partes ocultas de una fotografía o relacionando distintas vistas de un mismo objeto.

Este enfoque ha supuesto uno de los mayores avances de la Inteligencia Artificial en la última década. Gracias a él ha sido posible entrenar modelos utilizando cantidades masivas de texto, imágenes, audio o vídeo disponibles en Internet, sin necesidad de etiquetar manualmente cada ejemplo. Los grandes modelos fundacionales y los actuales sistemas de IA generativa son consecuencia directa de esta nueva forma de aprender.

1.4. Los algoritmos de aprendizaje

Hemos visto que una máquina puede aprender a partir de los datos, pero ese aprendizaje no se produce de forma espontánea. Es necesario un procedimiento que analice la información disponible, descubra relaciones entre ella y modifique progresivamente el comportamiento del modelo. Ese procedimiento recibe el nombre de **algoritmo de aprendizaje** y constituye el verdadero motor del *Machine Learning*.

Cada algoritmo ha sido diseñado para resolver una determinada familia de problemas: Algunos destacan clasificando información en categorías, otros predicen valores numéricos con gran precisión, otros descubren agrupaciones ocultas en los datos y otros aprenden a tomar decisiones mediante la interacción con un entorno. Incluso cuando varios algoritmos persiguen el mismo objetivo, cada uno lo hace siguiendo estrategias diferentes, con ventajas

e inconvenientes que dependen de la naturaleza de los datos y del problema que se pretende resolver.

A lo largo de los años fueron apareciendo algoritmos como la Regresión Lineal, Regresión Logística, k-Nearest Neighbors (k-NN), los Árboles de Decisión, Naive Bayes, las Support Vector Machines (SVM), Random Forest, k-Means, DBSCAN, PCA y muchos otros. Cada uno aportó nuevas ideas y permitió resolver con mayor eficacia determinados tipos de problemas, ampliando progresivamente las capacidades del *Machine Learning*.

Pero todos ellos compartían una característica común: cada algoritmo nacía para resolver una determinada familia de problemas. A medida que aparecían nuevos retos, era frecuente desarrollar nuevos algoritmos capaces de afrontarlos, este enfoque permitió un progreso extraordinario durante décadas, pero también planteó una cuestión inevitable: si los problemas del mundo real son prácticamente ilimitados, ¿es posible seguir diseñando un algoritmo diferente para cada uno de ellos?

Samuel, Arthur L. 1959. «Some Studies in Machine Learning Using the Game of Checkers». *IBM Journal of Research and Development* 3 (3): 210-29. <https://doi.org/10.1147/rd.33.0210>.