

Embeddings

Tabla de contenidos

1	Representar significado mediante números"	3
1.1	Qué es un embedding	3
1.2	Un espacio de representaciones	4
1.3	Del identificador al embedding	4
1.4	Similitud entre embeddings	5
1.5	Similitud no significa identidad	6
1.6	El significado depende del contexto	6
1.7	Embeddings iniciales y representaciones contextuales	7
1.7.1	Embedding inicial	7
1.7.2	Representación contextual	7
1.8	Embeddings de frases y documentos	8
1.9	Embeddings dentro de un sistema inteligente	8
1.10	Una representación aprendida, no una verdad objetiva	9
1.11	De representar a relacionar	9

1 Representar significado mediante números”

Después de dividir el texto en tokens, cada uno de ellos se identifica mediante un número dentro del vocabulario del modelo.

Sin embargo, ese identificador solo permite distinguir un token de otro. El número asignado no contiene por sí mismo información sobre su significado, su función o su relación con otros tokens.

Por ejemplo, que los tokens *gato* y *felino* tengan los identificadores 4.215 y 18.732 no indica que ambos conceptos estén relacionados. Los números actúan únicamente como referencias dentro de una tabla.

Para que el modelo pueda trabajar con semejanzas, diferencias y relaciones, cada token debe transformarse en una representación matemática más rica.

Esa representación recibe el nombre de **embedding**.

1.1. Qué es un embedding

Un embedding es un conjunto de valores numéricos que representa las características aprendidas de un elemento.

En un modelo de lenguaje, ese elemento puede ser:

- un token;
- una palabra;
- una frase;
- un párrafo;
- un documento completo;
- incluso una imagen, un fragmento de audio u otro tipo de información.

Podemos imaginar un embedding como una lista de números:

```
gato → [0.18, -0.42, 0.73, 0.09, ...]
```

En los modelos reales, estas representaciones pueden contener cientos o miles de valores.

Cada valor individual no suele corresponder a una característica fácilmente interpretable. No existe necesariamente una posición que signifique *animal*, otra que signifique *doméstico* y otra que signifique *mamífero*.

El significado se encuentra distribuido entre muchas dimensiones y surge de la combinación de todos esos valores.

1.2. Un espacio de representaciones

Los embeddings pueden interpretarse como posiciones dentro de un espacio matemático de muchas dimensiones.

En ese espacio, los elementos utilizados en contextos parecidos tienden a adquirir representaciones próximas o relacionadas.

Por ejemplo, podrían aparecer asociaciones entre términos como:

- *gato, perro y animal;*
- *Madrid, París y ciudad;*
- *programar, código y software;*
- *factura, pago y contabilidad.*

Esto no significa que el modelo contenga una definición formal de cada concepto.

Significa que, durante el entrenamiento, ha encontrado regularidades en la forma en que esos elementos aparecen y se relacionan dentro de los datos.

Una idea fundamental de los modelos de lenguaje es que gran parte de la información sobre el significado puede aprenderse observando el uso del lenguaje.

Las palabras que aparecen en contextos similares suelen desempeñar funciones o expresar conceptos relacionados.

1.3. Del identificador al embedding

Cuando el modelo recibe un token, utiliza su identificador para recuperar una representación inicial desde una tabla de embeddings.

De forma simplificada:

```
token
↓
identificador
↓
vector de embedding
```

Por ejemplo:

```
"servidor"  
  ↓  
  8431  
  ↓  
[0.14, -0.31, 0.82, ...]
```

Esta transformación convierte un identificador arbitrario en una representación numérica que el modelo puede procesar mediante operaciones matemáticas.

La tabla de embeddings forma parte de los parámetros del modelo y se ajusta durante el entrenamiento.

Por tanto, el ingeniero no asigna manualmente los valores asociados a cada token. El modelo los aprende a partir de los datos y del objetivo de entrenamiento.

1.4. Similitud entre embeddings

Una de las propiedades más útiles de los embeddings es que permiten medir matemáticamente la proximidad entre representaciones.

Dos embeddings pueden compararse para estimar si los elementos que representan guardan alguna relación.

Por ejemplo, un sistema podría determinar que una consulta sobre:

problemas al iniciar sesión

está relacionada con un documento titulado:

recuperación de acceso y contraseña

aunque ambos textos no utilicen exactamente las mismas palabras.

Esta capacidad se utiliza en numerosas soluciones:

- buscadores semánticos;
- sistemas de recomendación;
- clasificación de documentos;
- agrupación de contenidos;
- detección de duplicados;
- recuperación de información para sistemas RAG;
- comparación entre preguntas y respuestas;
- identificación de contenidos relacionados.

La búsqueda tradicional suele depender en gran medida de la coincidencia entre términos. La búsqueda mediante embeddings permite comparar representaciones aproximadas de su contenido.

Por ello, puede encontrar relaciones que no serían evidentes mediante una búsqueda literal.

1.5. Similitud no significa identidad

La proximidad entre embeddings debe interpretarse con precaución.

Dos representaciones pueden ser cercanas porque comparten:

- significado;
- tema;
- función;
- contexto de uso;
- estilo;
- estructura;
- asociaciones frecuentes.

Por ejemplo, *médico* y *hospital* pueden aparecer próximos aunque no sean conceptos equivalentes.

También pueden encontrarse próximos términos opuestos, como *frío* y *caliente*, porque aparecen en contextos lingüísticos parecidos.

Por tanto, la cercanía matemática no constituye una definición exacta del significado. Es una señal aprendida sobre las relaciones presentes en los datos.

1.6. El significado depende del contexto

Una palabra aislada puede tener varios significados.

Consideremos el término:

banco

Puede referirse a:

- una entidad financiera;
- un asiento;
- un conjunto de peces;
- una acumulación de arena;
- una reserva de datos o recursos.

Una representación fija del token no basta para determinar cuál de estas interpretaciones es correcta.

El significado depende de los demás elementos de la secuencia:

El banco aprobó el préstamo.

Nos sentamos en un banco del parque.

El barco atravesó un banco de arena.

El token inicial puede ser el mismo, pero su representación útil debe cambiar según el contexto en el que aparece.

Los modelos de lenguaje modernos resuelven este problema construyendo **representaciones contextuales**.

El embedding inicial proporciona un punto de partida, pero después el modelo lo transforma teniendo en cuenta los demás tokens de la secuencia.

Así, la representación de *banco* termina siendo diferente en cada uno de los ejemplos anteriores.

1.7. Embeddings iniciales y representaciones contextuales

Conviene distinguir dos momentos del procesamiento.

1.7.1. Embedding inicial

Es la representación que el modelo obtiene al identificar el token.

En esta fase, el token todavía no ha sido interpretado completamente dentro de la frase.

1.7.2. Representación contextual

Es la representación resultante después de relacionar el token con los demás elementos del contexto.

Esta representación incorpora información sobre:

- las palabras que lo rodean;
- su posición en la secuencia;
- la estructura de la frase;
- las referencias anteriores;
- el sentido que adquiere dentro del texto.

Podemos expresarlo de forma simplificada:

```
embedding inicial + contexto → representación contextual
```

El modelo no trabaja únicamente con una colección de palabras aisladas. Construye representaciones que evolucionan a medida que la información atraviesa sus distintas capas.

1.8. Embeddings de frases y documentos

Los embeddings no se utilizan únicamente para representar tokens.

También pueden generarse representaciones de unidades mayores, como frases o documentos completos.

Por ejemplo, las siguientes expresiones podrían producir embeddings próximos:

No puedo acceder a mi cuenta.

He olvidado mis credenciales de acceso.

Necesito recuperar mi contraseña.

Aunque no son idénticas, comparten una intención relacionada.

Un sistema puede utilizar esta proximidad para buscar documentos relevantes, clasificar solicitudes o recuperar información que posteriormente será proporcionada a un modelo de lenguaje.

En estos casos, el embedding no pretende reproducir cada detalle del texto. Produce una representación condensada de algunas de sus características más relevantes.

Esa condensación implica inevitablemente una pérdida de información. Por ello, un embedding resulta útil para encontrar o comparar contenidos, pero no sustituye al contenido original.

1.9. Embeddings dentro de un sistema inteligente

Los embeddings son una capacidad matemática que puede integrarse en distintos componentes de un sistema inteligente.

Por ejemplo, un sistema de atención al cliente podría:

1. recibir una consulta;
2. generar un embedding de la pregunta;
3. compararlo con embeddings de documentos internos;
4. recuperar los documentos más relacionados;
5. proporcionar esos documentos a un modelo de lenguaje;
6. generar una propuesta de respuesta;
7. validar el resultado antes de mostrarlo o enviarlo.

El embedding no responde a la pregunta ni toma una decisión. Permite localizar información potencialmente relevante.

De nuevo, observamos la diferencia entre una capacidad concreta y el sistema completo que la utiliza.

1.10. Una representación aprendida, no una verdad objetiva

Los embeddings se construyen a partir de los datos utilizados durante el entrenamiento.

Por ello, reflejan:

- las regularidades presentes en esos datos;
- las asociaciones frecuentes;
- sus limitaciones;
- sus desequilibrios;
- y también sus posibles sesgos.

Un espacio de embeddings no constituye una representación neutral y universal del conocimiento.

Es una representación aprendida para cumplir un objetivo determinado.

Su utilidad debe evaluarse dentro del sistema concreto, teniendo en cuenta los datos, el dominio, el idioma y las consecuencias de los posibles errores.

1.11. De representar a relacionar

Hasta ahora hemos recorrido el siguiente camino:

texto $\rightarrow$ tokens $\rightarrow$ identificadores $\rightarrow$ embeddings

Los embeddings proporcionan una representación matemática inicial de cada token.

Pero todavía queda una cuestión esencial:

¿Cómo determina el modelo qué partes del contexto son relevantes para interpretar cada token?

Para construir representaciones contextuales, el modelo debe relacionar unas posiciones de la secuencia con otras y calcular cuáles merecen mayor atención en cada momento.

Ese mecanismo recibe precisamente el nombre de **atención**.