

Attention

Tabla de contenidos

1	Atención: relacionar cada token con su contexto	3
1.1	Qué es la atención	3
1.2	La atención depende de la relación	4
1.3	Consultas, claves y valores	4
1.3.1	Consulta	5
1.3.2	Clave	5
1.3.3	Valor	5
1.4	Cálculo de la atención	5
1.5	Autoatención	6
1.6	Atención causal	7
1.7	Atención múltiple	7
1.8	Atención y posición	8
1.9	Atención no significa conciencia	9
1.10	Los pesos de atención no son una explicación completa	9
1.11	De la atención al Transformer	9

1 Atención: relacionar cada token con su contexto

Los embeddings proporcionan una representación matemática inicial de cada token. Sin embargo, el significado que adquiere un elemento dentro de una frase no depende únicamente de su representación aislada.

Para interpretar correctamente una secuencia, el modelo debe relacionar cada token con los demás tokens disponibles en el contexto.

Consideremos la siguiente frase:

La aplicación no pudo conectarse al servidor porque estaba apagado.

Para interpretar la expresión *estaba apagado*, el modelo debe relacionarla principalmente con *servidor*. Otros elementos de la frase aportan información, pero no todos tienen la misma relevancia para resolver esa relación.

El mecanismo que permite calcular dinámicamente qué partes de la secuencia resultan más relevantes para representar cada token recibe el nombre de **atención**.

1.1. Qué es la atención

La atención es un mecanismo que permite al modelo asignar distintos grados de importancia a los elementos de una secuencia.

Para construir la representación contextual de un token, el modelo:

1. compara ese token con los demás tokens disponibles;
2. calcula cuánto debe atender a cada uno;
3. asigna un peso a cada relación;
4. combina la información utilizando esos pesos.

De forma simplificada:

token actual + relaciones con el contexto $\rightarrow$ representación contextual

El resultado no es una selección única.

El modelo no elige necesariamente una palabra y descarta todas las demás. Distribuye diferentes pesos entre los tokens de la secuencia.

Por ejemplo, al procesar *apagado*, podría asignar:

- un peso elevado a *servidor*;
- cierta relevancia a *conectarse*;
- un peso menor a *aplicación*;
- muy poca relevancia a otros elementos.

Estos pesos no están definidos previamente mediante reglas lingüísticas. Se calculan para cada secuencia a partir de los parámetros aprendidos durante el entrenamiento.

1.2. La atención depende de la relación

Un token no tiene una importancia absoluta dentro del texto.

Su relevancia depende de:

- qué token se está procesando;
- qué información se necesita obtener;
- qué otros tokens forman parte del contexto;
- qué relaciones ha aprendido el modelo durante el entrenamiento.

En la frase:

El banco aprobó el préstamo.

el término *banco* se relaciona con *aprobó* y *préstamo*.

En cambio, en:

Nos sentamos en el banco del parque.

el mismo token se relaciona con *sentamos* y *parque*.

El embedding inicial puede ser semejante en ambos casos, pero el mecanismo de atención produce representaciones contextuales diferentes.

Por tanto, la atención permite que el significado operativo de un token se adapte a la secuencia en la que aparece.

1.3. Consultas, claves y valores

Para calcular la atención, el modelo genera tres representaciones diferentes a partir de cada token:

- **consulta** o *query*;
- **clave** o *key*;
- **valor** o *value*.

Estos tres conceptos suelen representarse mediante las letras **Q**, **K** y **V**.

1.3.1. Consulta

La consulta representa la información que el token necesita localizar en el contexto.

Podemos interpretarla como una pregunta matemática:

¿Qué información de los demás tokens resulta relevante para mí?

1.3.2. Clave

La clave representa el tipo de información que cada token puede ofrecer.

La consulta de un token se compara con las claves de los demás para calcular la intensidad de cada relación.

1.3.3. Valor

El valor contiene la información que el token aportará si se considera relevante.

La clave se utiliza para determinar cuánto atender al token. El valor proporciona la información que se incorporará al resultado.

Podemos resumirlo así:

la consulta busca, la clave permite comparar y el valor aporta información

Estas representaciones no se escriben manualmente. Se obtienen mediante transformaciones matemáticas cuyos parámetros se ajustan durante el entrenamiento.

1.4. Cálculo de la atención

El modelo compara cada consulta con las claves de los tokens disponibles.

Cuanto mayor sea la compatibilidad entre una consulta y una clave, mayor será normalmente el peso asignado a esa relación.

En el mecanismo denominado **atención por producto escalar escalado**, el cálculo se expresa mediante:

$$\text{Atención}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Esta expresión puede interpretarse en cuatro pasos:

1. QK^T compara las consultas con las claves.

2. La división por $\sqrt{d_k}$ reduce el efecto de valores excesivamente grandes y estabiliza el cálculo.
3. La función softmax transforma las puntuaciones obtenidas en pesos relativos.
4. Los pesos se aplican a los valores V para construir la representación resultante.

No es necesario realizar manualmente estas operaciones para utilizar un modelo, pero comprender su función permite abandonar una visión vaga de la atención.

La atención no es una intuición abstracta. Es un cálculo que produce una combinación ponderada de información.

1.5. Autoatención

Cuando las consultas, claves y valores proceden de la misma secuencia, hablamos de **auto-atención** o *self-attention*.

En una frase, cada token puede atender a los demás tokens de esa misma frase y construir su representación contextual.

De forma simplificada:

```
secuencia de tokens
      ↓
cada token se compara con los demás
      ↓
se calculan pesos de atención
      ↓
se generan representaciones contextuales
```

La autoatención permite establecer relaciones entre elementos aunque se encuentren separados dentro de la secuencia.

Por ejemplo:

El informe que presentó el equipo después de varias semanas de trabajo fue aprobado.

Para interpretar *fue aprobado*, el modelo debe conservar la relación con *informe*, aunque entre ambos aparezcan numerosos tokens.

A diferencia de otros enfoques anteriores que procesaban el texto principalmente de forma secuencial, la autoatención permite calcular directamente relaciones entre distintas posiciones.

1.6. Atención causal

Un modelo destinado a generar texto no debe utilizar información que todavía no ha sido generada.

Cuando predice el siguiente token, solo puede considerar los tokens anteriores.

Para garantizarlo se utiliza una **máscara causal**, que impide atender a posiciones futuras.

Por ejemplo, durante la generación de:

El sistema inteligente utiliza...

al predecir el token situado después de *utiliza*, el modelo puede atender a:

- *El*;
- *sistema*;
- *inteligente*;
- *utiliza*.

Pero no puede utilizar los tokens que todavía no existen.

Esta restricción mantiene el carácter autoregresivo de la generación:

contexto disponible → siguiente token → nuevo contexto → siguiente token

El proceso se repite hasta completar la respuesta.

1.7. Atención múltiple

Una única operación de atención puede concentrarse en un determinado tipo de relación.

Sin embargo, una secuencia contiene simultáneamente relaciones diferentes:

- sintácticas;
- semánticas;
- temporales;
- referenciales;
- estructurales;
- relacionadas con la posición;
- relacionadas con la tarea solicitada.

Por ello, el Transformer utiliza **atención multicabeza** o *multi-head attention*.

Cada cabeza de atención dispone de sus propias transformaciones para consultas, claves y valores. Esto permite que distintas cabezas aprendan a capturar diferentes relaciones dentro de la misma secuencia.

De forma conceptual:

representaciones	cabeza 1	relaciones sintácticas
	cabeza 2	referencias entre elementos
	cabeza 3	relaciones semánticas
	cabeza n	otros patrones aprendidos
		↓
		resultado combinado

No existe una asignación fija que obligue a cada cabeza a especializarse en una función concreta. Las relaciones emergen durante el entrenamiento y no siempre resultan fáciles de interpretar.

Los resultados de todas las cabezas se combinan para producir una nueva representación de cada posición.

1.8. Atención y posición

La autoatención compara los tokens de una secuencia, pero por sí sola no incorpora necesariamente su orden.

Las frases:

El perro persigue al gato.

y:

El gato persigue al perro.

contienen tokens semejantes, pero expresan relaciones diferentes debido a su posición.

Por esta razón, el Transformer incorpora información posicional a las representaciones de entrada. Esa información permite distinguir:

- qué token aparece antes;
- cuál aparece después;
- la distancia aproximada entre posiciones;
- el orden de los elementos dentro de la secuencia.

La atención relaciona los elementos. La información posicional permite interpretar esas relaciones dentro de una secuencia ordenada.

1.9. Atención no significa conciencia

El término *atención* procede de una analogía con la capacidad humana de concentrarse en determinados elementos.

Sin embargo, el mecanismo no implica:

- conciencia;
- intención;
- comprensión humana;
- interés;
- reflexión deliberada.

Se trata de una operación matemática aprendida que distribuye pesos entre representaciones.

El modelo no decide conscientemente prestar atención a una palabra. Calcula relaciones numéricas que han resultado útiles para reducir el error durante el entrenamiento.

1.10. Los pesos de atención no son una explicación completa

Los pesos de atención pueden ayudar a observar algunas relaciones internas del modelo, pero no deben considerarse automáticamente una explicación completa de su resultado.

Una salida se produce mediante:

- múltiples cabezas de atención;
- numerosas capas sucesivas;
- transformaciones adicionales;
- conexiones residuales;
- redes neuronales internas;
- interacciones distribuidas entre muchos parámetros.

Que un token reciba un peso elevado en una cabeza concreta no demuestra por sí solo que sea la causa única de la respuesta.

La atención aporta información sobre el procesamiento, pero no convierte automáticamente al modelo en un sistema transparente o completamente explicable.

1.11. De la atención al Transformer

Los mecanismos de atención ya se utilizaban antes de la aparición del Transformer, especialmente en sistemas de traducción automática (Bahdanau et al. 2015). Permitían seleccionar dinámicamente las partes de una secuencia de entrada más relevantes para generar cada elemento de la salida.

En 2017, Vaswani y sus colaboradores presentaron el artículo *Attention Is All You Need* (Vaswani et al. 2017). Su propuesta fue construir una arquitectura basada principalmente en mecanismos de atención, eliminando la necesidad de utilizar redes recurrentes o convolucionales como componentes centrales para procesar las secuencias.

Esa arquitectura recibió el nombre de **Transformer**.

El título del artículo resume su idea principal: la atención no sería únicamente un mecanismo auxiliar dentro de otra arquitectura. Podía convertirse en el fundamento sobre el que construir el modelo.

El recorrido realizado hasta ahora puede resumirse así:

texto $\rightarrow$ tokens $\rightarrow$ embeddings $\rightarrow$ atención $\rightarrow$ representaciones contextuales

En la siguiente sección reuniremos estas piezas para comprender la arquitectura que hizo posible el desarrollo de los grandes modelos de lenguaje modernos: el Transformer.

Bahdanau, Dzmitry, Kyunghyun Cho, y Yoshua Bengio. 2015. «Neural Machine Translation by Jointly Learning to Align and Translate». *International Conference on Learning Representations*.

Vaswani, Ashish, Noam Shazeer, Niki Parmar, et al. 2017. «Attention Is All You Need». *Advances in Neural Information Processing Systems* 30.